

Integração de dados e modelos preditivos no poço 861 (campo Lapa): perfil completo e plugs com microtomografia

Grupo de Pesquisa cs-regressor

Junho de 2026

Resumo

Este relatório descreve a Etapa 1 do projeto *methods_comparison* como **diagnóstico local** no poço 861 (campo Lapa): intervalo 5205,91–5233,72 m, 87 amostras perfil+laboratório e dez plugs com microtomografia (microCT). O objetivo foi verificar, *antes* da modelagem física de velocidades, quais propriedades petrofísicas os perfis convencionais conseguem prever com validação espacialmente honesta.

Foram testados dois cenários: (i) **perfil completo**—predição ao longo de todo o intervalo perfurado, com validação por blocos contíguos de profundidade; e (ii) **plugs com microCT**—predição plug a plug, deixando um plug de fora a cada rodada de teste.

Os principais resultados são: a porosidade medida em laboratório (ϕ_{lab}) é a única propriedade com coeficiente de determinação R^2 positivo e moderado ($R^2 \approx 0,15$) quando prevista apenas com perfis; a previsão direta do indicador de zona de fluxo (FZI_{lab}) falha ($R^2 \approx -0,82$). Um teste de referência (*oracle*), que usa porosidade e permeabilidade de laboratório como entrada, mostra que o FZI *pode* ser previsto quando essas informações estão disponíveis—o que indica limite de informação nas curvas de perfil, e não falha metodológica.

Complementarmente, testou-se reconstrução de curva de ϕ_{lab} por CLP-CSGM com laboratório esparsos nos dez plugs: a variante clássica com prior de floresta aleatória (RF) no espaço latente não superou o RF pontual ($\Delta\text{RMSE} \approx +0,005$ pu); a variante *residual* ($\hat{\phi} = \phi_{\text{RF}} + \delta$) quase empata com o RF ($\Delta\text{RMSE} \approx +0,0003$ pu) e vence no bloco superior.

Recomenda-se seguir para a Etapa 2 com modelos de meio efetivo (DEM/SC) calibrados por unidade hidrodinâmica de fluxo (HFU), em vez de investir em ajuste fino de algoritmos de aprendizado de máquina sobre perfis isolados.

1 Introdução

1.1 Contexto do poço e do projeto

O poço 861 foi caracterizado em três escalas: curvas de perfil registradas na perfuração, propriedades medidas em testemunhos de laboratório (porosidade, permeabilidade, FZI) e morfologia dos poros obtida por microCT em plugs de rocha.

O projeto *methods_comparison* busca, em etapas posteriores, estimar as velocidades sísmicas de compressão (V_p) e cisalhamento (V_s) por meio de modelos de meio efetivo—Differential Effective Medium (DEM) e Self-Consistent (SC), implementados no Pyrockphys—calibrados por HFU. Nesta fase *não* tentamos prever V_p ou V_s diretamente; o foco é responder: *o que os perfis conseguem prever de forma confiável antes de entrarmos na modelagem física?*

1.2 Propriedades avaliadas

- ϕ_{lab} : porosidade total medida em laboratório (pu).

- FZI_{lab} : Flow Zone Indicator, indicador de qualidade de zona de fluxo derivado de porosidade e permeabilidade de laboratório.
- k_{lab} : permeabilidade absoluta medida em laboratório (mD).
- HFU: Hydraulic Flow Unit, unidade hidrodinâmica de fluxo (classes 1 a 4 neste poço).

1.3 Organização do relatório

A Seção 2 apresenta os dados integrados. A Seção 3 explica como os modelos foram testados. As Seções 4–7 trazem os resultados do perfil e dos plugs. A Seção 8 documenta o CLP-CSGM com laboratório esparsos (Etapa 1f), incluindo o balanço dos termos do custo inverso, o papel de m , a limitação de fidelidade visual (Seção 8.9) e o estudo de sensibilidade (Seção 8.10). A Seção 9 interpreta os achados e a Seção 10 resume as recomendações.

2 Dados e integração (Etapa 1)

2.1 Fontes e resultados

Um fluxo automatizado de integração unificou perfis, resultados de laboratório e descritores de microCT em dois conjuntos analíticos (Tabela 1).

Tabela 1: Conjuntos de dados integrados do poço 861.

Conjunto	Uso	Amostras	Profundidade (m)
Perfil enriquecido com laboratório	Perfil ao longo do poço	87	5205,91–5233,72
Plugs integrados com microCT	Amostras plug a plug	10	plugs + perfil adjacente

Na Tabela 1, o conjunto de 87 amostras cobre quase 28 m de coluna perfurada e é a base principal para avaliar se os perfis preveem propriedades de laboratório ao longo do poço. Os dez plugs com microCT representam uma amostragem muito menor e mais cara: servem para calibrar propriedades de textura e geometria de poros, não para substituir o perfil completo. A sobreposição de apenas oito profundidades com CT indica que a maioria das amostras de perfil não possui imagem tridimensional associada—o microCT complementa, mas não cobre todo o intervalo.

No conjunto de 87 amostras, oito profundidades possuem plug de microCT associado. A consistência entre profundidades de plugs e perfis foi verificada por controle de qualidade da integração.

2.2 Variáveis de entrada e de saída

As curvas de perfil usadas como *entrada* dos modelos estão na Tabela 2. As *saídas* testadas foram ϕ_{lab} , FZI_{lab} , k_{lab} e HFU.

Importante: ao prever FZI, não podemos usar no modelo variáveis que já carregam a mesma informação do alvo (por exemplo, porosidade e permeabilidade de laboratório, que entram no cálculo do FZI). Essa regra—detalhada na Seção 3—evita que o modelo “cola” no resultado de laboratório em vez de aprender do perfil.

Tabela 2: Curvas de perfil usadas como entrada (perfil completo e plugs com microCT, somente perfil).

Curva	Significado
GR (API)	Gama raio
ρ_b (g/cc)	Densidade
R_t profunda e rasa	Resistividade
ϕ_N , ϕ_S , ϕ_{ND} (pu)	Porosidades estimadas pelo perfil
Litotipo	Código 1–4 (Tabela 3)

A Tabela 2 lista as oito curvas de perfil que um petrofísico usaria em uma interpretação convencional: litologia (GR, litotipo), porosidade (neutrón, sónica, densidade-neutrón) e fluido/rocha (resistividade). Não incluímos curvas derivadas de laboratório no conjunto de entrada, para que o modelo seja avaliado de forma justa: ele deve aprender apenas do que estaria disponível *antes* da análise de testemunho. No cenário com microCT, os descritores de imagem acrescentam informação de morfologia de poros que o perfil não resolve—por exemplo, forma e conectividade dos poros.

No cenário com perfil acrescido de descritores de microCT, acrescentam-se sete variáveis derivadas da imagem (porosidade da imagem, razão de aspecto dos poros, fração de sólidos corrigida, entre outros).

2.3 Distribuição de HFU

As classes de HFU não estão igualmente representadas: HFU1 ($n = 42$), HFU2 ($n = 29$), HFU3 ($n = 10$), HFU4 ($n = 6$). Esse desbalanceamento exige cautela na interpretação da acurácia dos classificadores (Seção 7). Em termos práticos, um modelo que sempre prediz HFU1 acertaria $42/87 \approx 48\%$ das amostras sem aprender padrão algum do perfil. Por isso, além da acurácia global, reportamos acurácia balanceada e F1 macro, que penalizam o desempenho nas classes minoritárias (HFU3 e HFU4).

2.4 Litotipos e classes HFU codificados

O poço 861 situa-se no **campo Lapa** (carbonatos pré-sal, Bacia de Santos); não confundir o nome do campo com o código de **Lithotype**. As fácies interpretadas em testemunho seguem a aba **Legend** de **Auddys_table.xlsx** (Tabela 3). A coluna **HFU** usa a mesma convenção da planilha (Tabela 4).

Tabela 3: Codificação de litotipos no perfil enriquecido ($n = 87$).

Código	Nome (Legend)	Amostras
1	Grainstone	25
2	Shrubs	42
3	Laminite	7
4	Spherulite	13

Tabela 4: Codificação de HFU (Hydrocarbon Flow Unit) no mesmo dataset.

Código	Classe (Legend)	Amostras
1	Poor	42
2	Medium	29
3	Good	10
4	Excellent	6

Na Tabela 3, *Shrubs* e *Spherulite* são os litotipos mais frequentes no intervalo; *Grainstone* concentra-se no bloco central de validação (Tabela 6). A variável **Lithotype** entra como feature categórica nos modelos de perfil (junto com GR e demais curvas wireline).

3 Protocolo de avaliação

3.1 Evitar uso indevido de variáveis de laboratório

Para cada propriedade alvo, excluimos do conjunto de entrada (X) as colunas que repetiria informação já presente no alvo (y). A Tabela 5 resume essas exclusões.

Tabela 5: Variáveis de laboratório excluídas da entrada, por alvo.

Alvo	Não usar como entrada
ϕ_{lab}	ϕ_{lab} , RQI, FZI _{lab}
FZI _{lab}	FZI _{lab} , ϕ_{lab} , k_{lab} , RQI, HFU
HFU	HFU, FZI _{lab} , RQI

Na Tabela 5, ao prever FZI, por exemplo, excluimos ϕ_{lab} e k_{lab} porque o FZI é calculado a partir dessas duas grandezas—usá-las como entrada faria o modelo “copiar” o resultado de laboratório, gerando R^2 artificialmente alto que não refletiria o poder preditivo real do perfil. A mesma lógica vale para RQI e HFU, que carregam informação redundante com FZI e permeabilidade.

3.2 Validação no perfil completo

Dividimos as 87 amostras em **três blocos contíguos de profundidade** (cerca de 29 amostras cada). Em cada rodada de validação (*fold*), dois blocos servem para treinar o modelo e o terceiro, reservado, serve para testar. Esse esquema—chamado *validação cruzada por blocos de profundidade*—simula a situação real de prever um intervalo que o modelo ainda não viu, sem misturar profundidades vizinhas entre treino e teste.

Cada amostra recebe uma predição *out-of-fold* (OOF): ela só entra no teste quando o seu bloco de profundidade está reservado, de modo que o modelo não viu aquela faixa no treino. As métricas e figuras de ϕ_{lab} nesta seção usam esse protocolo.

Isso contrasta com a divisão aleatória 80%/20%, que costuma *superestimar* o desempenho em dados de poço, pois amostras próximas em profundidade (e geologicamente semelhantes) acabam tanto no treino quanto no teste.

A Tabela 6 mostra que os três blocos são petrofisicamente distintos: o bloco central concentra *Grainstone* (litotipo 1) e a HFU1; o bloco inferior apresenta maior permeabilidade média e litotipos *Shrubs*, *Laminite* e *Spherulite*.

Tabela 6: Características médias de cada bloco de profundidade usado na validação ($n \approx 29$ amostras por bloco). Contagens de litotipo seguem a Tabela 3.

Bloco	Prof. (m)	$\overline{\text{FZI}}$	$\overline{\phi_{\text{lab}}}$ (pu)	$\overline{k_{\text{lab}}}$ (mD)	HFU1	HFU2	Grain. (1)	Shrubs (2)	Lamin. (3)	Spher. (4)
0	5206–5214	1,39	0,092	3,6	16	8	6	19	3	1
1	5215–5223	1,25	0,115	9,5	19	7	19	10	0	0
2	5225–5234	1,87	0,145	54,6	7	14	0	13	4	12

Em detalhe, o bloco 0 (5206–5214 m) é o mais “tight”: porosidade média de 0,092 pu e permeabilidade média de apenas 3,6 mD. O bloco 1 (5215–5223 m) concentra 19 das 29 amostras de *Grainstone* (litotipo 1) e é onde o modelo de FZI apresenta pior desempenho (Tabela 13)—o perfil não distingue bem as variações de textura nesse intervalo homogêneo em litologia. O bloco 2 (5225–5234 m) é o mais “permeável”: $\overline{k_{\text{lab}}} = 54,6$ mD e $\overline{\phi_{\text{lab}}} = 0,145$ pu, sem *Grainstone* (litotipo 1); predominam *Shrubs* e *Spherulite*; é também onde o RF de porosidade perde desempenho ($R^2 = -0,157$), sugerindo que a relação perfil–laboratório muda nesse subintervalo.

3.3 Validação nos plugs com microCT

Com apenas 10 plugs, usamos validação *leave-one-plug-out* (LOPO): em cada uma das dez rodadas, nove plugs treinam e um plug específico testa. O R^2 reportado é calculado sobre as dez predições feitas fora da amostra de treino (predições OOF, *out-of-fold*).

3.4 Modelos testados

Na Etapa 1c compararam-se cinco regressores: Random Forest (RF), Gradient Boosting, XGBoost, rede neural (MLP) e regressão linear. Na Etapa 1d/1e: RF para ϕ_{lab} ; Ridge e GAM como alternativas para porosidade; e regressão logística e RF balanceado para classificar HFU.

Não houve busca automática de hiperparâmetros nesta fase. O RF de produção usa 200 árvores de decisão e semente fixa para reprodutibilidade.

3.5 O que o R^2 informa

O R^2 compara o modelo com a média do treino. Perto de 1, acompanha a variação do alvo; perto de 0, equivale a prever essa média. Valor negativo não é “ajuste fraco”: o modelo erra *mais* do que a média — falha preditiva.

4 Diagnóstico: o que os perfis conseguem explicar? (Etapa 1c)

Antes de treinar modelos complexos, analisamos a correlação linear (Pearson) entre cada curva de perfil e cada propriedade alvo. Correlação alta sugere que a curva carrega informação útil; correlação baixa indica que o perfil, sozinho, dificilmente conseguirá prever aquela propriedade.

4.1 Correlação perfil–FZI

A Figura 1 mostra as correlações entre curvas de perfil e FZI_{lab} . A melhor curva de perfil (ϕ_{ND}) atinge apenas $r \approx 0,31$; gama raio e resistividade são praticamente nulas.

Em contraste, variáveis de laboratório—que não entram no modelo por serem derivadas do próprio FZI—correlacionam fortemente (Tabela 7). Isso explica por que o FZI é difícil de prever só com perfis: o sinal relevante está nas medidas de laboratório, não nas curvas.




Figura 1: Correlação de Pearson entre curvas de perfil e FZI_{lab} ($n = 87$). Barras curtas indicam pouca relação linear.

A Figura 1 confirma visualmente que todas as barras de correlação com curvas de perfil são curtas em comparação ao que seria necessário para uma predição confiável de FZI. A melhor curva (ϕ_{ND} , $r \approx 0,31$) explica menos de 10% da variância do FZI ($r^2 \approx 0,10$). Gama raio e resistividade praticamente não se relacionam com FZI neste intervalo—o que faz sentido geologicamente, pois FZI depende da geometria e conectividade dos poros (textura), não apenas da litologia ou do conteúdo de fluido detectado pelo perfil.

Tabela 7: Correlação de Pearson com FZI_{lab} : laboratório versus perfil.

Variável	r	$ r $
RQI (laboratório; excluída do modelo)	0,887	0,887
k_{lab} (excluída)	0,709	0,709
HFU (excluída para FZI)	0,614	0,614
Phi_ND (perfil)	0,308	0,308
GR (perfil)	-0,040	0,040

Na Tabela 7, o contraste entre laboratório e perfil é marcante. RQI (Quality Index) correlaciona com FZI em $r = 0,89$ porque ambos descrevem a mesma qualidade de zona de fluxo; permeabilidade ($r = 0,71$) e HFU ($r = 0,61$) também carregam essa informação. Já a melhor curva de perfil (ϕ_{ND}) atinge apenas $r = 0,31$ —cerca de três vezes menor que RQI. Isso antecipa o resultado regressivo: sem permeabilidade e textura de laboratório, o perfil não tem base suficiente para prever FZI.

4.2 Correlação perfil–porosidade

Para ϕ_{lab} , as porosidades de perfil são bem mais informativas (Tabela 8), o que é consistente com o melhor desempenho regressivo observado adiante (Seção 5).

Tabela 8: Correlação de Pearson com ϕ_{lab} (pu).

Variável	r
Phi_Neutron (perfil)	0,737
Phi_ND (perfil)	0,701
Density (perfil)	-0,670
Phi_Sonic (perfil)	0,667

Para porosidade, a Tabela 8 mostra situação oposta à do FZI: As três porosidades de perfil (ϕ_N , ϕ_{ND} , ϕ_S) correlacionam entre 0,67 e 0,74 com ϕ_{lab} —valores considerados fortes em petrofísica de carbonatos. A densidade apresenta correlação negativa ($r = -0,67$), coerente com o fato de que rocha mais densa tende a ser menos porosa. Esse alinhamento entre correlação e desempenho regressivo confirma que porosidade é a propriedade mais natural de se estimar a partir de perfis neste poço.

4.3 Teste de referência (*oracle*)

Para distinguir “falta de informação no perfil” de “modelo mal escolhido”, rodamos um experimento de referência: o RF recebe ϕ_{lab} e k_{lab} como entrada para prever FZI. Esse teste *oracle* não é aplicável em produção (usa dados de laboratório que não teríamos antes da análise), mas serve para diagnóstico.

A Figura 2 compara o desempenho bloco a bloco. Com perfis isolados, o modelo falha no bloco 1 ($R^2 \approx -1,95$). Com o teste *oracle*, o R^2 sobe para valores entre 0,37 e 0,88 nos blocos 0 e 1, com média global de aproximadamente 0,69. Confirmamos que o FZI *tem* sinal previsível—mas esse sinal vem de porosidade e permeabilidade de laboratório, não das curvas de perfil.




Figura 2: R^2 por bloco de profundidade para FZI_{lab} : apenas perfis versus teste *oracle* (ϕ_{lab} + k_{lab} de laboratório).

A Figura 2 ilustra dois cenários lado a lado para cada bloco de profundidade. Com perfis isolados (barras negativas no bloco 1), o modelo não consegue capturar a variação de FZI—o R^2 de $-1,95$ significa que as previsões são piores do que simplesmente usar a média do treino. Com

o teste *oracle* (porosidade e permeabilidade de laboratório como entrada), o R^2 sobe para valores entre 0,37 e 0,88, com média global de aproximadamente 0,69. A lição é direta: o FZI *contém* informação previsível, mas essa informação reside em propriedades medidas em laboratório, não nas curvas de perfil disponíveis. O problema não é o algoritmo (Random Forest), e sim o que o perfil consegue “ver” da textura do meio poroso.

5 Resultados no perfil completo

5.1 Comparação entre propriedades alvo

A Tabela 9 resume o Random Forest para três alvos. Apenas ϕ_{lab} apresenta R^2 médio positivo. A Figura 3 compara cada alvo com a referência de prever simplesmente a média do treino.

Tabela 9: Random Forest no perfil completo (validação por blocos de profundidade, $n = 87$). RMSE: erro quadrático médio.

Alvo	RMSE médio	R^2 médio	Desvio do R^2
Phi_lab (pu)	0,033	0,146	0,222
FZI_lab	1,813	−0,819	0,820
k_{lab} (mD)	76,2	−15,4	18,4




Figura 3: R^2 médio (RF, validação por blocos) para cada alvo, comparado à referência de prever a média.

Em conjunto, apenas porosidade supera a referência de prever a média; FZI e permeabilidade permanecem com R^2 negativo.

Porosidade ($R^2 = 0,146$, RMSE = 0,033 pu): o modelo explica cerca de 15% da variância de ϕ_{lab} , com erro típico de 0,033 porosidade absoluta (3,3 pontos percentuais). Para um intervalo com porosidade entre $\sim 0,07$ e $0,20$ pu, isso representa um erro relativo moderado—utilizável como insumo preliminar para DEM/SC, mas não como substituto da medição de laboratório. O desvio padrão do R^2 (0,222) indica que o desempenho varia bastante entre blocos (confirmado na Tabela 12).

FZI ($R^2 = -0,819$, $\text{RMSE} = 1,813$): resultado claramente inaceitável. Um R^2 negativo próximo de -1 significa que o modelo duplica o erro em relação a prever a média. Na Figura 3, a barra de FZI fica muito abaixo da linha de referência (média), confirmando a falha.

Permeabilidade ($R^2 = -15,4$, $\text{RMSE} = 76$ mD): o pior resultado. Permeabilidade em carbonatos costuma ter distribuição com cauda longa (valores que vão de menos de 1 mD a centenas de mD), o que dificulta qualquer regressão com apenas 87 amostras e oito curvas de perfil. O RMSE de 76 mD parece alto, mas reflete a enorme variância de k_{lab} no bloco 2 ($\bar{k} = 54,6$ mD com valores individuais muito maiores).

5.2 O algoritmo importa?

A Tabela 11 compara cinco algoritmos sob o mesmo protocolo, com colunas correspondentes a *alvos diferentes*. Para isolar o efeito do algoritmo em porosidade, a Tabela 10 resume apenas ϕ_{lab} ($n = 87$, previsões OOF em três blocos). Para FZI e permeabilidade em Tabela 11, *todos* falham. Isso reforça que o problema não está no tipo de algoritmo, e sim na quantidade de informação disponível nas curvas de perfil.

Tabela 10: Cinco regressores para ϕ_{lab} (perfil completo, previsões OOF, três blocos de profundidade).

Algoritmo	RMSE OOF (pu)	R^2 OOF médio
Random Forest	0,033	0,146
Regressão linear	0,036	-0,261
XGBoost	0,036	-0,099
Gradient Boosting	0,040	-0,313
Rede neural (MLP)	0,097	-6,871

Tabela 11: Comparação de cinco regressores no perfil completo: R^2 OOF médio por alvo (cada coluna é um alvo distinto).

Algoritmo	ϕ_{lab}	FZI _{lab}	k_{lab}
Random Forest	0,146	-0,819	-15,4
Rede neural (MLP)	-6,871	-0,251	-0,026
XGBoost	-0,099	-2,308	-72,0
Regressão linear	-0,261	-2,392	-24,2
Gradient Boosting	-0,313	-1,582	-22,2

Na Tabela 10, o Random Forest é o único com R^2 positivo em ϕ_{lab} ; os demais variam entre $-0,10$ (XGBoost) e $-6,87$ (MLP). O MLP, em particular, apresenta $R^2 = -6,87$ —sinal de que a rede neural, com poucos dados e sem ajuste de hiperparâmetros, não é adequada aqui. Para FZI, todos os algoritmos falham, embora o MLP ($R^2 = -0,25$) pareça “menos ruim” que o RF—isso *não* significa que MLP é melhor: R^2 negativo próximo de zero ainda indica desempenho inaceitável, e a diferença entre algoritmos é pequena frente ao limite informacional identificado no diagnóstico (Seção 4). Para permeabilidade, o MLP ($R^2 = -0,03$) também parece competitivo, mas novamente todos os valores são negativos ou próximos de zero—nenhum modelo é viável para prever k_{lab} a partir de perfis.

5.3 Porosidade de laboratório: modelo principal

O RF para ϕ_{lab} atinge RMSE médio de 0.033 pu e $R^2 = 0,146$ (Tabela 12). O desempenho varia por bloco: os blocos 0 e 1 são positivos; o bloco 2 é negativo, coincidindo com o intervalo de

maior permeabilidade média (Tabela 6).

Tabela 12: RF para ϕ_{lab} : resultado em cada bloco de teste.

Bloco	Prof. teste (m)	RMSE	R^2	Amostras de teste
0	5206–5214	0,015	0,367	29
1	5215–5223	0,037	0,227	29
2	5225–5234	0,047	−0,157	29
Média	–	0,033	0,146	–

A Tabela 12 revela *onde* o modelo funciona e onde falha.

Bloco 0 (5206–5214 m): $R^2 = 0,367$, RMSE = 0,015 pu—o melhor resultado. Este intervalo tem menor porosidade e permeabilidade (Tabela 6), e a relação entre porosidades de perfil e ϕ_{lab} é mais estável.

Bloco 1 (5215–5223 m): $R^2 = 0,227$, RMSE = 0,037 pu—desempenho positivo, porém mais fraco. Predomina *Grainstone* (litotipo 1); o erro aumenta porque a variabilidade de ϕ_{lab} dentro do bloco é menor e mais difícil de capturar.

Bloco 2 (5225–5234 m): $R^2 = -0,157$, RMSE = 0,047 pu—o modelo falha neste intervalo. Aqui a permeabilidade média salta para 54,6 mD e a porosidade média para 0,145 pu, sem *Grainstone* (litotipo 1). O perfil parece responder de forma diferente neste subintervalo mais permeável, e o modelo treinado nos outros blocos não generaliza.

Em resumo: o R^2 médio de 0,146 mascara desempenho heterogêneo—bom nos dois blocos superiores, ruim no inferior.

As Figuras 4–5 mostram o desempenho *ao longo da profundidade*, com o mesmo protocolo OOF das tabelas: observado (tracejado) versus predito (colorido) para RF, Gradient Boosting, MLP e regressão linear; linhas horizontais tracejadas indicam os limites entre blocos de teste. A Figura 5 quantifica o RMSE OOF por bloco: RF e regressão linear lideram; MLP degrada fortemente no bloco 2.




Figura 4: ϕ_{lab} ao longo da profundidade: observado (tracejado) e previsões OOF por regressor (RF, Gradient Boosting, MLP e regressão linear). Mesmo protocolo da Tabela 12 ($n = 87$, oito curvas wireline, três blocos).






Figura 5: RMSE OOF por bloco de profundidade para ϕ_{lab} (RF, GB, MLP e LR). O erro cresce no bloco 2 em todos os algoritmos.

RF (verde): acompanha ϕ_{lab} nos blocos 0–1 e desvia no bloco profundo. *Regressão linear (azul)*: desempenho próximo ao RF neste poço. *MLP (vermelho)*: instável e coerente com $R^2 \ll 0$ na Tabela 10. As figuras OOF de profundidade foram geradas no pipeline de comparação de regressores da Etapa 1d.

A Figura 6a (painel abaixo) mostra predito versus observado numa divisão aleatória 80/20 (apenas ilustrativa; a métrica oficial é a validação por blocos e as predições OOF acima). A Figura 6b indica quais curvas mais influenciam as predições do RF (análise SHAP: contribuição de cada variável para cada predição).



(a) Predito versus observado (divisão 80/20, ilustrativo).



(b) Contribuição das curvas (SHAP).

Figura 6: Complementos do RF para ϕ_{lab} (não substituem as figuras OOF).

A Figura 6 complementa a análise em dois painéis secundários.

Painel (a)—predito versus observado: Os pontos deveriam alinhar-se à diagonal (predição perfeita). O agrupamento geral ao longo da diagonal indica que o RF captura a tendência de

porosidade, mas com dispersão visível—consistente com $R^2 = 0,146$ na validação por blocos. Esta figura usa divisão aleatória 80/20 e tende a parecer melhor do que a validação por blocos; por isso a tratamos apenas como ilustração.

Painel (b)—importância SHAP: As barras indicam quais curvas mais influenciam as predições do RF. Espera-se que ϕ_N , ϕ_{ND} e ρ_b dominem, pois são as curvas com maior correlação com ϕ_{lab} (Tabela 8). Se curvas de litologia (GR, litotipo) aparecerem com peso relevante, isso sugere que o modelo usa informação litológica para ajustar a porosidade estimada—comportamento razoável em carbonatos com múltiplos litotipos.

5.4 FZI de laboratório: falha na generalização

O RF para FZI_{lab} (Tabela 13) confirma o colapso no bloco 1, onde predomina *Grainstone* (litotipo 1). Uma divisão aleatória 80/20 daria $R^2 \approx 0,17$ —resultado enganoso, pois mistura profundidades semelhantes entre treino e teste.

Tabela 13: RF para FZI_{lab} : resultado em cada bloco de teste.

Bloco	Prof. teste (m)	RMSE	R^2
0	5206–5214	1,30	−0,015
1	5215–5223	2,14	−1,945
2	5225–5234	2,00	−0,496
Média	–	1,81	−0,819

Na Tabela 13, o colapso no bloco 1 ($R^2 = -1,945$) é o resultado mais relevante. Este bloco concentra *Grainstone* (19 de 29 amostras, litotipo 1) e tem FZI médio relativamente baixo ($\overline{FZI} = 1,25$), mas com variabilidade interna que o perfil não captura. O RMSE de 2,14 neste bloco representa erro substancial frente à faixa típica de FZI no poço. No bloco 0, o $R^2 \approx 0$ indica desempenho equivalente à média; no bloco 2, $R^2 = -0,496$ confirma falha também no intervalo mais permeável.

Compare com o resultado enganoso de uma divisão aleatória 80/20 ($R^2 \approx 0,17$): esse valor *superestima* a capacidade preditiva porque amostras do bloco 1 aparecem tanto no treino quanto no teste. A validação por blocos expõe a fragilidade real do modelo.

6 Resultados nos plugs com microCT

Com apenas 10 amostras, os resultados devem ser interpretados com cautela. A Tabela 14 reporta o R^2 global das predições OOF do RF.

Para FZI_{lab} , usar somente curvas de perfil superou incluir descritores de microCT. Para ϕ_{lab} , ambos os modos deram R^2 negativo. A Figura 7 mostra o ajuste plug a plug para FZI.

Tabela 14: RF nos 10 plugs: R^2 global (validação LOPO).

Alvo	Somente perfil	Perfil + microCT
FZI_{lab}	0,151	0,116
Φ_{lab} (pu)	−0,334	−0,466




Figura 7: LOPO-RF para FZI_{lab} nos plugs: predito versus observado (somente curvas de perfil).

Lidos em conjunto, os resultados nos dez plugs exigem cautela extrema na extrapolacao ao perfil completo.

FZI nos plugs ($R^2 = 0,151$ somente perfil; $0,116$ com microCT): o valor positivo fraco sugere que, com apenas dez amostras, o RF captura alguma tendência de FZI a partir das curvas de perfil adjacentes a cada plug. Porém, incluir descritores de microCT *piorou* levemente o resultado ($0,151 \rightarrow 0,116$)—provavelmente por overfitting: sete variáveis extras em um conjunto de dez amostras aumentam o risco de o modelo memorizar padrões específicos de cada plug em vez de aprender relações gerais.

Na Figura 7, cada ponto corresponde a um plug identificado individualmente. A dispersão em torno da diagonal indica predições com erro plug a plug; não há evidência de ajuste sistemático preciso. Com dez pontos, um único plug mal predito altera fortemente o R^2 global.

Porosidade nos plugs ($R^2 = -0,334$ somente perfil; $-0,466$ com microCT): ambos negativos. Os dez plugs não representam bem a variabilidade das 87 amostras do perfil completo—a porosidade dos plugs pode diferir da porosidade média do intervalo perfurado nas mesmas profundidades. Este resultado confirma que a análise nos dez plugs não substitui o perfil completo de 87 amostras para estimar porosidade ao longo do poço.

O R^2 positivo fraco de FZI nos dez plugs *não* significa que o modelo generaliza para as 87 amostras do perfil completo: o conjunto de plugs é pequeno e cada plug removido altera bastante o resultado.

7 Alternativas de modelo (Etapa 1e)

7.1 Porosidade: modelos mais simples versus RF

Testamos se um modelo mais simples poderia igualar o RF para ϕ_{lab} . A Tabela 15 e a Figura 8 comparam Ridge (regressão linear com penalização), GAM (modelo aditivo generalizado, aqui aproximado por splines + Ridge) e o RF.

Nenhuma alternativa superou o RF. O GAM foi aproximado por splines cubicas seguidas de regressão Ridge, por indisponibilidade da biblioteca especializada no ambiente de execução.

Tabela 15: ϕ_{lab} : comparação entre RF, GAM e Ridge.

Modelo	RMSE médio (pu)	R^2 médio
RF (referência)	0,033	0,146
GAM (spline+Ridge)	0,036	−0,052
Ridge	0,037	−0,261




Figura 8: R^2 médio para ϕ_{lab} : RF, GAM e Ridge.

O RF permanece superior: $R^2 = 0,146$ contra $-0,052$ (GAM) e $-0,261$ (Ridge). O Ridge, sendo um modelo linear, assume relação fixa entre curvas e porosidade—o que falha quando a relação muda entre blocos litológicos (Tabela 6). O GAM permite relações não lineares por curva, mas a implementação disponível (splines + Ridge) não superou o RF, possivelmente porque 87 amostras são poucas para estimar curvas flexíveis com estabilidade entre blocos. Na Figura 8, a barra do RF é a única acima da linha de referência ($R^2 = 0$); Ridge e GAM ficam abaixo, confirmando que modelos mais simples não compensam a limitação de informação do perfil.


7.2 Classificação de HFU

A Tabela 16 resume a acurácia das predições OOF. A regressão logística com pesos balanceados superou o RF balanceado, mas a acurácia global ($\approx 36\%$) continua modesta: em quatro classes, o acaso corresponde a cerca de 25%.


A *acurácia balanceada* dá peso igual a cada classe, evitando que o modelo pareça bom apenas por acertar a classe majoritária (HFU1).

Tabela 16: Classificação de HFU (validação por blocos, previsões OOF).

Modelo	Acurácia	Acurácia balanceada	F1 macro
Logística balanceada	0,356	0,220	0,217
RF balanceado	0,299	0,179	0,161



(a) Métricas por modelo.



(b) Matriz de confusão (logística).

Figura 9: Classificação de HFU no perfil completo.

A logística balanceada supera o RF em todas as métricas da Figura 9a, embora o desempenho global continue modesto.

Acurácia global (logística: 35,6%; RF: 29,9%): a regressão logística acerta pouco mais de um terço das amostras. Para quatro classes, o chute aleatório daria ~25%; o ganho sobre o acaso é de apenas 10 pontos percentuais—desempenho modesto.

Acurácia balanceada (logística: 22,0%; RF: 17,9%): ao dar peso igual a cada HFU, o desempenho cai abaixo do acaso (25%). Isso indica que o modelo tem dificuldade especial nas classes minoritárias HFU3 ($n = 10$) e HFU4 ($n = 6$).

F1 macro (logística: 0,217; RF: 0,161): métrica que combina precisão e revocação por classe; valores próximos de 0,2 confirmam desempenho fraco e heterogêneo entre HFUs.

Na Figura 9a, a logística supera o RF em todas as métricas—modelos lineares tendem a generalizar melhor com poucos dados e classes desbalanceadas. Na Figura 9b, a matriz de confusão mostra onde ocorrem os erros: espera-se confusão entre HFU1 e HFU2 (classes mais frequentes e petrofisicamente mais próximas), e poucos acertos em HFU3 e HFU4. Para a Etapa 2, a HFU de laboratório deve ser priorizada; a predição automática serve apenas como recurso auxiliar onde não houver amostra de laboratório.

8 CLP-CSGM com laboratório esparsos nos plugs (Etapa 1f)

8.1 Motivação e pergunta científica

Na Etapa 1d, o RF responde à pergunta pontual: *wireline sozinho prevê ϕ_{lab} em cada profundidade?* Com $R^2 \approx 0,15$ (Tabela 12), o perfil já carrega sinal útil, porém com erro heterogêneo entre blocos.

A Etapa 1f pergunta de forma complementar:

Com wireline denso ao longo da janela ($\mathbf{u}$) e ϕ_{lab} medida apenas nos dez plugs ($\mathbf{b}$), é possível reconstruir a curva $\phi(z)$ ao longo do intervalo de forma estruturalmente correta, sem tratar laboratório como feature de entrada?

O arcabouço CLP-CSGM (Compressed Learning Problem com generative prior no espaço latente) impõe consistência esparsa $\|M G(\mathbf{z}) - \mathbf{b}\|_2^2$ entre a curva reconstruída $G(\mathbf{z})$ e as amarras de laboratório, em vez de concatenar ϕ_{lab} ao vetor de features—o que causaria vazamento informacional na validação.

Neste poço, o desafio é severo: apenas dez plugs em 87 amostras e oito profundidades únicas com amarra fixa; o RF pontual já é forte no bloco superior. A motivação do experimento não é substituir o RF por default, e sim testar se amarras esparsas de laboratório *refinam* o perfil quando a formulação inversa é honesta.

8.2 Notação por janela deslizante

Seguimos janelas de comprimento $L = 16$ amostras e passo unitário ao longo das 87 profundidades. Para cada janela:

- $\mathbf{y} \in \mathbb{R}^L$: curva de ϕ_{lab} na janela (alvo de referência na validação, não usada em $\mathbf{u}$).
- $\mathbf{u}$: oito curvas wireline na mesma janela (GR, densidade, resistividades, ϕ_N , ϕ_S , ϕ_{ND} , litotipo), idênticas à Etapa 1d.
- $M \in \{0, 1\}^{m \times L}$: matriz de subsampling por *coordenada*; m é o número de plugs dentro da janela (máscara fixa, não amostragem aleatória ρ).
- $G(\mathbf{z}) = \text{Dec}(\mathbf{z})$: decodificador do autoencoder (AE) treinado offline nas janelas de treino do fold.
- $\mathbf{z}_0$: código latente de prior condicional.
- $\lambda > 0$: peso de regularização Tikhonov no latente.

A validação repete o protocolo de três blocos contíguos da Seção 3: em cada fold, o RF e o AE só veem dados de treino; as métricas OOF comparam predições pontuais nas 87 profundidades com o mesmo RF de referência.

8.3 Problema inverso CLP-CSGM (formulação base)

Dado $\mathbf{b}$ e M , o recuperador CSGM resolve, para cada janela de teste,

$$\mathbf{z}^* = \arg \min_{\mathbf{z}} \frac{1}{m} \|M G(\mathbf{z}) - \mathbf{b}\|_2^2 + \lambda \|\mathbf{z} - \mathbf{z}_0\|_2^2, \quad (1)$$

onde m é o número de linhas de M (plugs na janela). O balanço entre o termo de dados e o prior latente, o caso $m = 0$ e a leitura janela a janela nas variantes A e B são detalhados na Seção 8.4.

A âncora $\mathbf{z}_0$ *não* é apenas chute inicial do otimizador: ela entra explicitamente no custo (1) e equilibra aderência às medidas esparsas versus permanência próxima ao prior latente. O hiperparâmetro λ é escolhido por grade no conjunto de validação interno de cada fold (20% do pool de treino).

A curva predita na janela depende da variante (Seção 8.6). Predições de janelas sobrepostas são fundidas por média uniforme ao longo da profundidade (mesma regra de *stitching* OOF usada nas figuras de ϕ_{lab}).

8.4 Balanço do custo inverso e papel de m

A equação (1) combina duas fontes de informação com papéis distintos. O termo de dados $\|M G(\mathbf{z}) - \mathbf{b}\|_2^2$ impõe consistência com o **laboratório esparsos** nos índices selecionados por M : em cada coordenada-plug, a curva reconstruída deve aproximar o valor prescrito em $\mathbf{b}$. O termo de prior $\lambda \|\mathbf{z} - \mathbf{z}_0\|_2^2$ penaliza desvios de um **centro latente** $\mathbf{z}_0$ que resume a crença *a priori* antes de olhar as amarras daquela janela—seja $h(\mathbf{u})$, $\text{Enc}(\hat{\phi}_{\text{RF}})$ ou $\text{Enc}(\mathbf{0})$, conforme a variante.

Nenhum dos dois termos “carrega a informação” sozinho em todas as situações: quem domina depende de m , de λ e de como a predição final é montada (somente $G(\mathbf{z})$ na variante A versus $\hat{\phi}_{\text{RF}} + G(\mathbf{z})$ na variante B). A Tabela 17 resume os regimes.

Tabela 17: Regimes do inverso (1) por número de plugs na janela (m) e variante.

m	Termo ativo	Otimização em $\mathbf{z}$?	Papel dominante
0	só $\lambda \ \mathbf{z} - \mathbf{z}_0\ _2^2$; M e $\mathbf{b}$ vazios	não; $\mathbf{z} = \mathbf{z}_0$	prior latente (e, na B, $\hat{\phi}_{\text{RF}}$)
≥ 1	dados + prior	sim; trade-off via λ	lab nos plugs + prior + AE ao longo de L

8.4.1 Caso $m = 0$: ausência de plug na janela

Com dez plugs em 87 amostras e janelas de $L = 16$, *muitas* janelas deslizantes não contêm nenhuma profundidade-plug: para elas, M tem dimensão $0 \times L$ e $\mathbf{b} \in \mathbb{R}^0$. O termo de dados desaparece, porque $\|M G(\mathbf{z}) - \mathbf{b}\|_2^2 = 0$ para qualquer $\mathbf{z}$. O recuperador *não executa* iterações de gradiente: fixa $\mathbf{z} = \mathbf{z}_0$ e devolve $G(\mathbf{z}_0)$ decodificado.

Esse mecanismo é **comum às variantes A e B**. A diferença está no *significado* de $\mathbf{z}_0$ e na fórmula da saída—não na presença ou ausência do termo de dados.

Variante A com $m = 0$. Com $\mathbf{z}_0 = \text{Enc}(\hat{\phi}_{\text{RF}})$ no AE_ϕ ,

$$\hat{\phi} = G_\phi(\mathbf{z}_0) = G_\phi(\text{Enc}(\hat{\phi}_{\text{RF}})). \quad (2)$$

Trata-se de *reconstruir* a curva RF passando pelo autoencoder treinado em ϕ_{lab} . Em geral, $G_\phi(\text{Enc}(\hat{\phi}_{\text{RF}})) \not\approx \hat{\phi}_{\text{RF}}$ ponto a ponto: o encode-decode introduz erro de reconstrução e o manifold de ϕ_{lab} não coincide com o das predições RF. Mesmo “só prior”, a variante A **não** devolve o RF cru.

Variante B com $m = 0$. Com $\mathbf{z}_0 = \text{Enc}(\mathbf{0})$ no AE_δ ,

$$\hat{\phi} = \hat{\phi}_{\text{RF}} + G_\delta(\mathbf{z}_0) \approx \hat{\phi}_{\text{RF}} + \mathbf{0}. \quad (3)$$

Aqui $\text{Enc}(\mathbf{0})$ é a âncora latente: codifica “resíduo nulo” no espaço em que o AE foi treinado (após padronização). Não se fixa $\mathbf{z} = \mathbf{0}$ literalmente em $\mathbb{R}^k$ —isso não garantiria $G_\delta(\mathbf{0}) = \mathbf{0}$ em escala física. A baseline wireline $\hat{\phi}_{\text{RF}}$ entra **explicitamente** na soma; o prior só controla a correção δ_ϕ , que colapsa quando não há amarra.

8.4.2 Caso $m \geq 1$: plug(s) dentro da janela

Quando há pelo menos um plug, $\mathbf{b}$ é não vazio e o otimizador ajusta $\mathbf{z}$ equilibrando dados e prior. O hiperparâmetro λ , escolhido por grade na validação interna, controla esse balanço:

- λ **grande**: o inverso permanece próximo de $\mathbf{z}_0$; a curva fica suave e pode subajustar os plugs.

- λ **pequeno**: o termo $\|MG(\mathbf{z}) - \mathbf{b}\|^2$ pesa mais; a reconstrução aproxima $\mathbf{b}$ nos índices medidos.

Importante: M seleciona apenas m coordenadas, mas $G(\mathbf{z})$ é uma *curva completa* de comprimento L . O autoencoder acopla todos os índices da janela: a correção imposta no plug propaga-se, via G e via λ , às profundidades vizinhas dentro da mesma janela.

Na variante A, $\mathbf{b} = M\phi_{\text{lab}}$ ancora ϕ absoluta. Na variante B, $\mathbf{b} = M(\phi_{\text{lab}} - \hat{\phi}_{\text{RF}})$ ancora o *desvio* do RF; a saída $\hat{\phi} = \hat{\phi}_{\text{RF}} + G_{\delta}(\mathbf{z}^*)$ ainda soma a baseline em toda a janela.

8.4.3 Leitura no perfil completo (87 profundidades)

O perfil OOF final funde janelas sobrepostas por média uniforme. Cada profundidade é coberta por várias janelas, algumas com $m = 0$ e outras com $m \geq 1$. Por isso o comportamento *global* é uma mistura:

- trechos onde predominam janelas com $m = 0$ tendem a seguir o *default* do prior (e, na B, o RF);
- trechos próximos a plugs recebem contribuição de janelas com $m \geq 1$, nas quais o laboratório altera $\mathbf{z}^*$ e, por extensão, a curva ao longo de L .

No poço 861, o laboratório só fixa oito profundidades com amarra; a maior parte do intervalo é coberta sobretudo por janelas sem plug. Isso explica por que a variante B quase reproduz o RF globalmente (Tabela 20): a informação wireline já está em $\hat{\phi}_{\text{RF}}$, e $\|z - z_0\|^2$ só modula *quanto* desviar—não reconstrói ϕ do zero como na variante A. A degradação da variante A ($\Delta\text{RMSE} = +0,005$ pu) reflete, em parte, janelas $m = 0$ em que $G_{\phi}(\text{Enc}(\hat{\phi}_{\text{RF}}))$ se afasta do RF pontual, e janelas $m \geq 1$ em que $G_{\phi}(\mathbf{z}^*)$ suaviza ou desloca a curva inteira.

O que o leitor deve reter. O prior $\|z - z_0\|^2$ define o **comportamento padrão** de cada janela quando o laboratório não fala ($m = 0$) ou fala pouco (λ grande). Ele *não* substitui, em geral, a informação wireline—exceto indiretamente via $\mathbf{z}_0$. Na variante B, a informação wireline dominante está em $\hat{\phi}_{\text{RF}}$; o inverso latente estima apenas o resíduo local exigido por $\mathbf{b}$ nos plugs.

8.5 Papel do prior latente $\mathbf{z}_0$: três construções e por que importam

O termo $\lambda\|\mathbf{z} - \mathbf{z}_0\|_2^2$ em (1) penaliza desvios do código latente em relação a um *centro de prior*. A escolha de $\mathbf{z}_0$ define qual curva (ou correção) o inverso prefere quando as amarras $\mathbf{b}$ são escassas ou ausentes (m pequeno ou $m = 0$). Não se trata de mera inicialização numérica: $\mathbf{z}_0$ permanece no objetivo durante toda a otimização.

No arcabouço CLP-CSGM original, o prior condicional mapeia informação abundante para o latente:

$$\mathbf{z}_0 = h(\mathbf{u}), \quad (4)$$

com h Ridge ou rede rasa treinada para aproximar $\text{Enc}(\text{AE}, \mathbf{y})$ a partir de $\mathbf{u}$ *somente nos dados de treino do fold*. Essa é a construção (I) $h(\mathbf{u})$, usada nas variantes Ridge/MLP da Etapa 1f.

Por que (I) não basta no poço 861. O mapeamento $h(\mathbf{u})$ aprende um centro latente a partir do wireline, mas a curva decodificada $G(\mathbf{z}_0)$ não coincide, em geral, com a melhor predição pontual de ϕ_{lab} já obtida na Etapa 1d. Na prática, Ridge/MLP em $h(\mathbf{u})$ com AE em ϕ absoluta produziram RMSE médio por janela de 0,049–0,051 pu (três *seeds*), sistematicamente acima do RF pontual (0,036 pu na comparação OOF alinhada). Ou seja: priorizar um $\mathbf{z}_0$ derivado só de $\mathbf{u}$ no espaço latente de ϕ *não garante* que a reconstrução final herde a qualidade do RF, porque G foi treinado no manifold de ϕ_{lab} e não no manifold das predições RF.

Construção (II): $\mathbf{z}_0 = \text{Enc}(\hat{\phi}_{\text{RF}})$. Para alinhar o prior ao melhor baseline wireline, codifica-se no AE a *curva* RF na janela (vetor $\hat{\phi}_{\text{RF}} \in \mathbb{R}^L$, não o vetor de features $\mathbf{u}$):

$$\mathbf{z}_0 = \text{Enc}(\text{AE}_\phi, \hat{\phi}_{\text{RF}}). \quad (5)$$

Note a distinção conceitual: $h(\mathbf{u})$ opera no espaço de *entradas* (dimensão das features concatenadas na janela); já $\text{Enc}(\hat{\phi}_{\text{RF}})$ opera no *espaço de saída* em que o AE foi treinado (curvas de ϕ de comprimento L). Não existe, nesta pipeline, um $\text{Enc}(\mathbf{u})$ —o encoder consome curvas-alvo, não perfis wireline isolados.

A intenção de (II) é puxar $\mathbf{z}$ para um latente cujo decode reproduza aproximadamente a curva RF *no manifold* de ϕ . Porém a predição final é $G(\mathbf{z}^*)$ inteira: o RF entra só na regularização, não na soma final. Quando λ é pequeno ou há poucos plugs, $G(\mathbf{z}^*)$ pode afastar-se da curva RF que motivou $\mathbf{z}_0$, reconstruindo ϕ absoluta com suavização do AE—daí a degradação observada na variante A (Tabela 20).

Construção (III): $\mathbf{z}_0 = \text{Enc}(\mathbf{0})$ no AE de resíduos. Na variante residual, o AE modela δ_ϕ , não ϕ absoluta. O prior neutro é *correção nula*:

$$\mathbf{z}_0 = \text{Enc}(\text{AE}_\delta, \mathbf{0}), \quad (6)$$

com $\mathbf{0} \in \mathbb{R}^L$ antes da padronização (resíduo médio nulo na escala física).

Por que não usar $h(\mathbf{u})$ na variante B? O wireline já entra explicitamente em $\hat{\phi}_{\text{RF}}$, que é a baseline *fora* do inverso (1). Definir $\mathbf{z}_0 = h(\mathbf{u})$ no AE de δ_ϕ misturaria dois papéis: (i) informação já absorvida pelo RF na baseline; (ii) centro latente para δ_ϕ , cuja interpretação física seria opaca (wireline não é resíduo). O prior $\text{Enc}(\mathbf{0})$ expressa diretamente a hipótese “*não corrigir o RF*” quando não há amarra de laboratório; com $m = 0$, $\hat{\delta}_\phi \approx \mathbf{0}$ e $\hat{\phi} \approx \hat{\phi}_{\text{RF}}$.

Por que não $\text{Enc}(\hat{\phi}_{\text{RF}})$ no AE δ ? Esse código corresponderia a um resíduo *não nulo* no manifold do AE—ou seja, a baseline deixaria de ser correção zero e o inverso partiria de um viés sistemático em δ_ϕ , anulando a decomposição (8).

A Tabela 18 resume os três centros latentes e o efeito esperado sobre a predição.

Tabela 18: Três construções de $\mathbf{z}_0$ no CLP-CSGM e papel na predição de ϕ_{lab} (poço 861).

ID	Definição de $\mathbf{z}_0$	Espaço do AE	Efeito quando $m = 0$
(I)	$h(\mathbf{u})$ Ridge/MLP	ϕ_{lab}	$G(\mathbf{z}_0)$: curva ϕ genérica do wireline, não necessariamente RF
(II)	$\text{Enc}(\hat{\phi}_{\text{RF}})$	ϕ_{lab}	$G(\mathbf{z}_0) \approx \hat{\phi}_{\text{RF}}$ no manifold ϕ , mas $\hat{\phi} = G(\mathbf{z}^*)$ pode divergir
(III)	$\text{Enc}(\mathbf{0})$	δ_ϕ	$\hat{\delta}_\phi \approx \mathbf{0}$, $\hat{\phi} = \hat{\phi}_{\text{RF}}$

Em síntese: (I) é o prior CLP canônico, insuficiente quando o RF pontual já é forte; (II) melhora o *centro latente* em ϕ , mas não ancora a *resposta final*; (III) alinha prior, baseline e objetivo —corrigir só o que o laboratório esparsos exige.

8.6 Variantes experimentais

8.6.1 Variante A: prior RF no espaço de ϕ_{lab} (CLP clássico)

Esta variante combina AE em ϕ absoluta com a construção (II): $\mathbf{z}_0 = \text{Enc}(\hat{\phi}_{\text{RF}})$ conforme (5).

$$\mathbf{b} = M\mathbf{y} = M\phi_{\text{lab}}. \quad (7)$$

A predição final é $\hat{\mathbf{y}} = G(\mathbf{z}^*)$ —ou seja, o RF entra somente em $\mathbf{z}_0$ e *não* na resposta final. Interpretação: o CSGM tenta *reconstruir a curva inteira* de ϕ_{lab} , puxada ao RF no latente mas livre para se afastar dele na decodificação quando λ é pequeno ou quando poucas amarras constroem $\mathbf{b}$.

Variantes com construção (I), $h(\mathbf{u})$ Ridge ou MLP, estão documentadas na Tabela 18; não superaram o RF pontual (RMSE por janela $\approx 0,049$ – $0,051$ pu).

8.6.2 Variante B: CLP residual sobre o RF

Quando o RF já explica boa parte da variância, reconstruir ϕ absoluta força o inverso a repetir trabalho que o wireline resolve. A variante B usa a construção (III) da Seção 8.5 e *reparametriza* o problema:

$$\delta_\phi = \phi_{\text{lab}} - \hat{\phi}_{\text{RF}}, \quad \hat{\phi} = \hat{\phi}_{\text{RF}} + \delta_\phi. \quad (8)$$

Treino do AE. O autoencoder é treinado em curvas δ_ϕ das janelas de treino (não em ϕ_{lab} bruto), após subtrair $\hat{\phi}_{\text{RF}}$ ponto a ponto em cada janela, com o mesmo RF do fold.

Prior latente. Adotamos $\mathbf{z}_0 = \text{Enc}(\mathbf{0})$ no AE_δ , conforme (6) e a justificativa da Seção 8.5: na ausência de medidas ($m = 0$), $\hat{\delta}_\phi \approx \mathbf{0}$ e $\hat{\phi} \approx \hat{\phi}_{\text{RF}}$.

Medidas esparsas. As amarras observam desvios nos plugs:

$$\mathbf{b} = M \delta_\phi = M(\phi_{\text{lab}} - \hat{\phi}_{\text{RF}}). \quad (9)$$

Inverso. Resolve-se (1) com G decodificando δ_ϕ ; a seleção de λ minimiza RMSE de $\hat{\phi}$ (não de δ_ϕ) no conjunto de validação interno.

Equivalência nas amarras. Substituindo (8) em (9), impor $M G(\mathbf{z}^*) = \mathbf{b}$ é equivalente a $M \hat{\phi} = M \phi_{\text{lab}}$: o residuo ainda ancora a curva final nos valores de laboratório nos plugs, mas parametriza a solução como correção local sobre um baseline já otimizado para wireline.

8.7 Comparação conceitual das duas variantes

Tabela 19: CLP-CSGM plug-fixed: contraste entre reconstrução absoluta (prior RF) e residual sobre RF.

Aspecto	Variante A (prior RF)	Variante B (residual RF)
Espaço do AE	ϕ_{lab} absoluta	$\delta_\phi = \phi_{\text{lab}} - \hat{\phi}_{\text{RF}}$
Prior $\mathbf{z}_0$	(II) $\text{Enc}(\hat{\phi}_{\text{RF}})$	(III) $\text{Enc}(\mathbf{0})$ no AE_δ
Medida $\mathbf{b}$	$M \phi_{\text{lab}}$	$M(\phi_{\text{lab}} - \hat{\phi}_{\text{RF}})$
Saída	$G(\mathbf{z}^*)$	$\hat{\phi}_{\text{RF}} + G(\mathbf{z}^*)$
Sem plug na janela ($m = 0$)	$\hat{\phi} = G_\phi(\text{Enc}(\hat{\phi}_{\text{RF}}))$ (RF via AE, não RF cru)	$\hat{\phi} = \hat{\phi}_{\text{RF}} + G_\delta(\text{Enc}(\mathbf{0})) \approx \hat{\phi}_{\text{RF}}$

A Tabela 19 resume por que a variante residual é o candidato natural quando o RF já é baseline oficial da Etapa 1d: o inverso deixa de competir com o wireline na escala absoluta e passa a estimar somente o que o laboratório esparsa ainda pode corrigir. O contraste na linha $m = 0$ é central: ambas as variantes perdem o termo de dados (Seção 8.4), mas só a B preserva o RF pontual como resposta padrão.

8.8 Resultados: CLP versus RF pontual (OOF alinhado)

As Tabelas 20 e 21 reportam comparação *ponto a ponto* nas 87 profundidades, com o mesmo protocolo de blocos e o mesmo RF de referência em cada fold (*seed* 7; detalhes na seção de reprodutibilidade).

Tabela 20: CLP plug-fixed versus RF pontual OOF ($n = 87$, *seed* 7). $\Delta\text{RMSE} = \text{RMSE}_{\text{CLP}} - \text{RMSE}_{\text{RF}}$.

Método	RMSE (pu)	R^2	ΔRMSE (pu)
RF pontual (referência)	0,036	0,304	–
CLP prior RF (variante A)	0,040	0,106	+0,005
CLP residual RF (variante B)	0,036	0,290	+0,000

Tabela 21: CLP versus RF por bloco de profundidade (*seed* 7).

Bloco	Prof. (m)	RMSE_{RF}	RMSE_A	Δ_A	RMSE_B	Δ_B
0	5206–5214	0,016	0,017	+0,001	0,015	–0,001
1	5215–5223	0,037	0,040	+0,003	0,037	0,000
2	5225–5234	0,046	0,054	+0,008	0,047	+0,001
Global	–	0,036	0,040	+0,005	0,036	+0,000

Na Tabela 20, a variante A (prior RF no latente, reconstrução absoluta) *piora* o RF em cerca de 0,005 pu e reduz o R^2 de 0,30 para 0,11: o CSGM suaviza e reconstrói janelas de forma que o ganho teórico das amarras nos plugs não compensa o afastamento do RF pontual já ajustado ao wireline.

A variante B quase *empata* globalmente ($\Delta\text{RMSE} \approx +0,0003$ pu, arredondado a zero na tabela) e recupera $R^2 \approx 0,29$, próximo do RF. Na Tabela 21, o bloco 0—menor porosidade e melhor desempenho do RF na Etapa 1d—é o único em que o CLP residual *supera* o RF ($\Delta = -0,001$ pu, R^2 0,35 contra 0,29). No bloco 2 (regime mais permeável, $R_{\text{RF}}^2 < 0$), ambas as variantes CLP degradam frente ao RF, porém a residual limita a perda a +0,001 pu, contra +0,008 pu da variante A.

A Figura 10 compara, lado a lado, os três perfis OOF em profundidade: RF pontual, CLP variante A e CLP variante B, todos contra ϕ_{lab} observado (tracejado). No painel central, a variante A desvia visivelmente do RF no bloco inferior; no painel direito, a variante B permanece colada ao RF na maior parte do intervalo e só se separa nas vizinhanças das amarras de laboratório. A Figura 11 reúne as três previsões num único painel para leitura global.




Figura 10: Perfis OOF de ϕ_{lab} ao longo da profundidade (*seed* 7): observado (tracejado) versus RF pontual, CLP prior RF (variante A) e CLP residual RF (variante B), em painéis lado a lado. Linhas horizontais pontilhadas: limites entre blocos de teste.




Figura 11: Mesmas curvas da Figura 10 em painel único: comparação direta das três predições OOF.

8.9 Limitação visual e fidelidade à ϕ_{lab} observada

As Tabelas 20 e 21 medem erro agregado (RMSE, R^2); a Figura 11 expõe um limite complementar: **nenhuma** das três predições reproduz a *morfologia fina* da curva de ϕ_{lab} observada ao longo de todo o intervalo. As curvas RF e CLP são visivelmente mais *suaves* que o observado (tracejado): picos e vales de laboratório (amplitude até $\approx 0,22$ pu e quedas abaixo de 0,08 pu) são atenuados pelas reconstruções, que permanecem em faixa estreita ($\approx 0,08$ – $0,16$ pu na maior parte do poço).

A Tabela 22 quantifica esse descompasso (*seed* 7, 87 profundidades OOF). A razão $\sigma_{\text{pred}}/\sigma_{\text{obs}}$ mede quanto da variabilidade de ϕ_{lab} cada método preserva: valores bem abaixo de 1 indicam *compressão* da amplitude. A correlação de Pearson r resume o alinhamento global; a coluna $r(\Delta)$ correlaciona *variações sucessivas* ao longo da profundidade—proxy da capacidade de reproduzir oscilações locais entre amostras adjacentes.

Tabela 22: Fidelidade da curva OOF à ϕ_{lab} observada (*seed* 7, $n = 87$). $\sigma_{\text{obs}} = 0,043$ pu.

Método	$\sigma_{\text{pred}}/\sigma_{\text{obs}}$	r	$r(\Delta)$	MAE (pu)
RF pontual	0,59	0,58	0,09	0,027
CLP prior RF (A)	0,37	0,59	0,10	0,029
CLP residual RF (B)	0,50	0,63	0,13	0,027

Tabela 23: RMSE OOF nas oito profundidades-plug versus demais amostras (*seed* 7).

Método	RMSE nos plugs (pu)	RMSE fora dos plugs (pu)
RF pontual	0,026	0,036
CLP prior RF (A)	0,016	0,042
CLP residual RF (B)	0,027	0,037

Na Tabela 22, as três abordagens capturam menos de 60% do desvio padrão observado; a variante A comprime ainda mais ($\sigma_{\text{pred}}/\sigma_{\text{obs}} \approx 0,37$), coerente com a suavização adicional do AE em ϕ absoluta. Os valores de $r(\Delta) \approx 0,09$ – $0,13$ confirmam que nem RF nem CLP acompanham a *alta frequência* da série de laboratório de amostra em amostra—apenas a tendência de baixa frequência visível na Figura 11.

A Tabela 23 explica por que a variante A piora globalmente apesar de parecer próxima do observado em alguns trechos: nas oito profundidades com plug na máscara fixa, o RMSE da A (0,016 pu) é o menor dos três; *fora* dos plugs, porém, sobe para 0,042 pu—pior que o RF (0,036 pu). O CLP absoluto ajusta melhor localmente onde há amarra, mas distorce o intervalo entre plugs. A variante B mantém RMSE fora dos plugs (0,037 pu) próximo ao RF e só oferece refinamento modesto nos plugs.

Por que as curvas “não conversam” com o observado. Quatro mecanismos se somam, além do limite informacional do wireline já discutido na Seção 9 (Tabela 8):

1. **Escala de informação.** Correlações fortes entre porosidades de perfil e ϕ_{lab} ($r \approx 0,7$) não implicam reprodução ponto a ponto: o perfil integra um volume lateral distinto do testemunho de laboratório, com heterogeneidade subescala que as oito curvas wireline não resolvem.
2. **Suavização estrutural.** O AE em janelas de $L = 16$, o *stitching* por média e o termo $\lambda\|z - z_0\|^2$ impõem curvas latentes regulares; o inverso não interpola ϕ_{lab} exata em cada profundidade, e sim uma reconstrução acoplada ao longo da janela (Seção 8.4).

3. **Esparsidade das amarras.** Dez plugs em 87 amostras deixam a maior parte das janelas com $m = 0$; o laboratório altera o perfil apenas onde janelas com plug passam, sem fixar cada amostra.
4. **Validação honesta.** Na validação por blocos, o bloco de teste não entra no treino; no bloco 2 (Tabela 21) todos os métodos degradam, pois o wireline responde de forma distinta no intervalo mais permeável.

Leitura para o modelo petrofísico. Se o critério de sucesso for *replicar visualmente* a curva de ϕ_{lab} em todas as 87 amostras, os resultados da Etapa 1f são **insatisfatórios** em todos os casos—incluindo a variante B, que só empata o RF em RMSE global sem ganho visual decisivo. Se o critério for *estimar tendência de porosidade* condicionada ao perfil (e fracamente ao lab nos plugs), o RF e a variante B permanecem *marginalmente aceitáveis* como insumo preliminar para a Etapa 2, com a mesma ressalva do bloco inferior já documentada na Seção 5. O CLP deve ser interpretado como experimento de formulação inversa sem vazamento, não como substituto operacional da curva de laboratório.

8.10 Estudo de sensibilidade e teto informacional

Para verificar se a baixa fidelidade visual (Seção 8.9) poderia ser corrigida por ajuste de hiperparâmetros do autoencoder ou do otimizador latente, executamos um estudo complementar com *seed* 7 e o mesmo protocolo de blocos: (i) baselines de teto informacional e interpolação mecânica; (ii) ablação *one-factor-at-a-time* (OFAT) na variante B (CLP residual), variando um parâmetro por vez em relação ao default ($L = 16$, latente = 16, oculto = 128, 200 épocas AE, $\text{lr}_{\text{opt}} = 0,05$).

Tabela 24: Baselines e teto informacional para ϕ_{lab} ($n = 87$, *seed* 7). ϕ_{ND} e ϕ_N : curva de perfil usada diretamente (sem ML).

Caso	Tipo	RMSE (pu)	R^2	σ ratio	$r(\Delta)$
ϕ_{ND} perfil	wireline	0,032	0,446	0,87	0,27
ϕ_N perfil	wireline	0,039	0,164	0,98	0,27
RF pontual OOF	ML	0,036	0,304	0,59	0,09
Spline linear nos plugs	mecânico	0,090	−3,49	2,07	−0,08
CLP residual (default)	CLP-B	0,036	0,290	0,50	0,13

Tabela 25: Ablação OFAT na variante B (CLP residual): ΔRMSE em relação ao default (pu). Nenhuma variação altera $\sigma_{\text{pred}}/\sigma_{\text{obs}}$ de forma relevante (faixa 0,49–0,50 em todos os casos).

Fator variado	Valores testados	ΔRMSE (pu)
Dimensão latente	8, 32	0,000, −0,0001
Camada oculta AE	64, 256	0,000, 0,000
Épocas AE	100, 400	−0,000, −0,000
lr otimizador z	0,01, 0,10	0,000, 0,000
Comprimento janela L	8, 24	−0,0004, −0,000

Na Tabela 24, o uso direto de ϕ_{ND} do perfil atinge o menor RMSE (0,032 pu) e a maior razão de variância preservada (σ ratio = 0,87), porém *ainda abaixo de 1*: nem o melhor log de perfil reproduz toda a variabilidade da ϕ_{lab} . A porosidade de nêutron fica próxima em amplitude (σ ratio $\approx 0,98$), mas com RMSE maior. O RF OOF e o CLP default ficam em σ ratio $\approx 0,59$ e 0,50, respectivamente—confirmando a leitura visual da Figura 11. A interpolação linear OOF

entre os plugs de treino por bloco falha fortemente ($\text{RMSE} = 0,090$ pu, $R^2 \ll 0$): poucas amarras não sustentam uma curva de laboratório entre blocos sem informação de perfil.

A Tabela 25 mostra que alterar profundidade efetiva da rede, taxa de aprendizado do inverso, épocas do AE ou comprimento de janela ($L = 8\text{--}24$) desloca o RMSE global em no máximo 0,0004 pu e *não* eleva σ ratio para a faixa do observado. A melhor janela curta ($L = 8$) melhora marginalmente RMSE e $r(\Delta)$, mas mantém σ ratio $\approx 0,50$: captura um pouco mais de variação local, porém longe de reproduzir os picos da curva preta. Na seleção interna de λ por fold, o valor escolhido ficou no *mínimo* da grade (0,0001) na variante B—ou seja, o modelo já preferia confiar mais no termo de dados do que no prior latente; a baixa fidelidade de alta frequência não é explicada por super-regularização.

Conclusão do estudo de sensibilidade. Os resultados apoiam a hipótese de **limite informacional e estrutural** (wireline + poucos plugs + suavização do AE/stitching), e **não** de hiperparâmetro mal ajustado: mesmo ϕ_{ND} direto—upper bound simples do perfil— não atinge σ ratio = 1; a ablação OFAT do CLP-B é estável em RMSE e em amplitude. Investimento adicional em *tuning* de rede ou otimizador, neste poço e protocolo, tem retorno esperado baixo frente a usar ϕ_{ND} ou RF como tendência e reservar ϕ_{lab} para calibração pontual.

8.11 Síntese da Etapa 1f

O experimento confirma que *ter* laboratório esparsos nos plugs não garante superar o RF pontual se a formulação reconstrói ϕ absoluta: a variante A fica claramente abaixo do baseline. A reparametrização residual preserva o RF onde não há amarra e delega ao CSGM apenas correções locais—comportamento alinhado à física do problema (wireline domina a escala global; laboratório calibra pontos). Ainda assim, no poço 861, o ganho global da variante B é marginal e não altera a recomendação principal da Etapa 1: usar RF ou ϕ_{ND} como insumo de porosidade para a Etapa 2. A Seção 8.9 mostra que, além das métricas agregadas, as curvas recuperadas *não reproduzem* a variabilidade fina da ϕ_{lab} observada—limitação estrutural e informacional, não falha de implementação isolada. O estudo de sensibilidade (Seção 8.10) confirma essa leitura com baselines de teto (ϕ_{ND} , spline nos plugs) e ablação OFAT de hiperparâmetros. O CLP residual permanece documentado como alternativa metodológica quando se deseja fundir perfil e amarras de laboratório sem vazamento, com expectativa realista de refinamento local e não de substituição do RF em todo o intervalo nem de réplica visual da curva de laboratório.

9 Discussão

Esta seção sintetiza os achados das tabelas e figuras anteriores sob três eixos: limite de informação do perfil, papel da validação geológica e encaminhamento para a modelagem física de velocidades.

9.1 O problema é a informação, não o algoritmo

Os resultados negativos para FZI e permeabilidade não indicam erro no pipeline de dados ou nos scripts. O teste *oracle* (Figura 2) mostra que o FZI *tem* sinal previsível quando porosidade e permeabilidade de laboratório estão disponíveis (Tabela 7)—mas essas variáveis são justamente excluídas do modelo para que ele aprenda apenas do perfil.

Trocar RF por rede neural, GAM ou regressão linear não muda essa conclusão para FZI (Tabela 11). Para porosidade, o RF permaneceu o melhor entre regressores pontuais (Tabela 15), embora o ganho seja modesto ($R^2 \approx 0,15$). O CLP-CSGM com laboratório esparsos (Seção 8) não superou o RF na formulação absoluta com prior RF; a variante residual quase empata globalmente e melhora localmente no bloco superior, mas não altera o papel do RF como estimativa principal ao longo do poço. O estudo de sensibilidade da Seção 8.10 indica que ajuste fino de arquitetura

ou otimizador do CLP não recupera a variabilidade fina da ϕ_{lab} ; o teto informacional do perfil (ϕ_{ND} direto) também permanece abaixo da variância observada.

9.2 Porosidade: único resultado utilizável

O encadeamento diagnóstico $\rightarrow$ regressão confirma coerência interna dos resultados. A Tabela 8 mostra correlações fortes ($r > 0,67$) entre porosidades de perfil e ϕ_{lab} ; a Tabela 12 mostra R^2 positivo nos blocos 0 e 1 e negativo no bloco 2. Na prática, isso significa que o RF de porosidade pode ser usado como *estimativa preliminar* ao longo do poço, com ressalva explícita para o intervalo 5225–5234 m, onde o modelo perde validade. As Figuras 11 e a Tabela 22 reforçam que nem RF nem CLP replicam a morfologia fina da ϕ_{lab} observada—apenas tendência de baixa frequência. Uma alternativa conservadora é usar diretamente ϕ_{ND} do perfil, sem modelo de aprendizado de máquina, quando a simplicidade for preferível.

9.3 FZI e permeabilidade: descartados como alvo de perfil

O FZI resume textura e qualidade de zona de fluxo—propriedades que o perfil convencional não mede diretamente. A Figura 1, a Tabela 7 e o teste *oracle* (Figura 2) contam a mesma história: o perfil não vê o que o laboratório vê. A permeabilidade apresenta ainda maior dificuldade: distribuição com cauda longa (bloco 2, Tabela 6) e R^2 fortemente negativo em todos os algoritmos (Tabela 11).

9.4 Por que a validação por blocos importa

A validação por blocos de profundidade expõe mudanças litológicas reais (Tabela 6). No bloco 1, onde predomina *Grainstone* (litotipo 1), o modelo de FZI colapsa (Tabela 13). Métricas obtidas com divisão aleatória 80/20 devem ser vistas apenas como referência histórica, não como prova de que o modelo funcionaria em um intervalo novo do poço.

9.5 Papel do microCT nesta fase

Incluir descritores de microCT não melhorou o RF nos dez plugs (Tabela 14). Isso não diminui o valor do microCT para o projeto: na Etapa 2, a geometria dos poros (razão de aspecto, fração de sólidos) servirá para calibrar os modelos DEM/SC, e não como variável extra num regressor de perfil.

9.6 Caminho para V_p/V_s (Etapa 2)

A cadeia recomendada, em ordem, é:

1. Estimar porosidade a partir do perfil (ϕ_{lab} via RF ou ϕ_{ND} diretamente).
2. Segmentar o intervalo por HFU (preferir HFU de laboratório; a predição por logística da Tabela 16 é apenas um recurso auxiliar).
3. Usar geometria de poros dos dez plugs CT para parametrizar DEM/SC.
4. Calcular V_p e V_s teóricos por HFU no Pyrockphys.
5. Só então considerar aprendizado de máquina sobre resíduos (Etapa 3), após validar a modelagem física.

10 Conclusões e recomendações

1. **Porosidade:** manter RF (ou ϕ_{ND} do perfil) como insumo para DEM/SC. O $R^2 \approx 0,15$ é modesto, mas é o único resultado regressivo estável no perfil completo. O CLP residual sobre RF (Etapa 1f) quase reproduz esse patamar, porém sem ganho global decisivo; usar apenas se amarras esparsas de laboratório forem obrigatórias na entrega de curva.
2. **FZI:** não usar previsão direta a partir de perfis como modelo final. O perfil não carrega informação suficiente.
3. **HFU:** priorizar classificação de laboratório; a predição automática (36% de acurácia) serve apenas como recurso auxiliar (*fallback*).
4. **microCT:** avançar para Etapa 2, usando os dez plugs para calibrar geometria de poros nos modelos DEM/SC.
5. **Ajuste de modelos:** adiar busca fina de hiperparâmetros até definir claramente os insumos da modelagem física.
6. **Motivação para a Etapa 2:** o limite não é apenas algorítmico—é de **informação nas curvas de perfil** para FZI, permeabilidade e velocidades. Isso justifica investir em física de rochas (DEM/SC + microCT + HFU de laboratório), não em mais *tuning* de ML perfil $\rightarrow V_p$.

Disponibilidade dos dados e reprodutibilidade

A integração de perfis, laboratório e microCT, bem como os protocolos de validação, treinamento e diagnóstico descritos neste relatório, foram implementados de forma automatizada e reprodutível. Os conjuntos processados, métricas numéricas e figuras podem ser obtidos mediante solicitação aos autores ou acesso ao repositório do projeto de pesquisa.

Os experimentos CLP da Seção 8 usam máscara fixa nos dez plugs, validação por três blocos de profundidade e comparação OOF alinhada ao RF pontual; as tabelas reportadas referem-se à *seed* 7 (junho de 2026). Os valores numéricos e figuras comparativas podem ser reproduzidos a partir dos artefatos tabulares do repositório do projeto, mediante solicitação aos autores. O estudo de sensibilidade da Seção 8.10 (baselines, ablação OFAT da variante B) pode ser repetido com o orquestrador dedicado de sensibilidade da Etapa 1f (*seed* 7).