

Poço 861 (campo Lapa)

Etapa 3 — HFU e regressores

Onde o corretor reduz o erro e se o algoritmo muda o resultado

Romulo Brito da Silva

UENF / LENEP

Agosto de 2026

Mesmo residual OOF da apresentação anterior ($R^2 \approx 0,79$)

Foco: estratificação por HFU e comparação entre regressores



Laboratório de
**Engenharia e Exploração
de Petróleo - LENEP**



Grupo de Inferência de Reservatório
UENF - CCT - LENEP

Roteiro

1. Nos slides anteriores, o residual ΔV_p mostrou-se previsível em profundidade. Aqui: *onde* o ganho aparece e *com qual* algoritmo.
2. MAPE e viés por HFU (rótulos de amostra intercalados; não zonas contíguas de profundidade).
3. O que os plugs da calibração DEM/SC explicam no Gassmann e o que não explicam no híbrido.
4. Seis regressores: mesmo ΔV_p , mesmas oito entradas em X .
5. Hiperparâmetros fixados e justificativa.
6. Linear versus Ridge; RF versus linear em profundidade.

Da apresentação anterior para esta

O que já ficou definido

- Cadeia elástica (DEM/SC + Gassmann) **fixa**; o sônico entra apenas no alvo.
- Residual $\Delta V_p = V_{p,\text{sônico}} - V_{p,\text{Gassmann}}$; o modelo estima $g(X) \approx \mathbb{E}[\Delta V_p | X]$.
- OOF em três blocos de profundidade: $R^2 \approx 0,79$, RMSE residual $\approx 0,18$ km/s.
- Produto híbrido:
$$V_{p,\text{híbrido}} = V_{p,\text{Gassmann}} + \widehat{\Delta V_p}.$$

Perguntas desta apresentação

- Em quais HFUs o híbrido reduz mais o erro?
- A falta de plugs explica o desvio do Gassmann — ou também o erro que sobra no híbrido?
- O RF oficial (Etapa 1) continua competitivo diante dos demais regressores?
- CLP, janelas e transferência a outro poço ficam para depois.

Métrica usada aqui: $\text{MAPE} = \frac{1}{n} \sum_i |V_{p,\text{híbrido},i} - V_{p,\text{sônico},i}| / V_{p,\text{sônico},i}$ (híbrido OOF em relação ao DSI).

Erro por HFU, depois do corretor

A HFU de laboratório **não** entra em X : serve só para agrupar as 87 predições OOF. Em profundidade, os rótulos estão **intercalados** — não formam intervalos contíguos $z_a - z_b$.

HFU	n	MAPE (%)		Viés (km/s)	
		Gass.	Híbr.	Gass.	Híbr.
1	42	6,8	2,2	+0,33	+0,02
2	29	2,2	2,3	-0,11	-0,09
3	10	11,5	5,4	+0,51	+0,15
4	6	28,1	4,8	+1,31	+0,17

HFU 2

Gassmann já estava em 2,2%; o híbrido fica em 2,3%. Quando a física já fecha, o corretor quase não altera o resultado — e não piora.

Onde o corretor reduz o erro

- **HFU 4** ($n = 6$, sem plugs / fallback): 28,1% $\rightarrow$ 4,8%.
- **HFU 3** (dois plugs): 11,5% $\rightarrow$ 5,4%.
- **HFU 1** (42/87 amostras): 6,8% $\rightarrow$ 2,2%; puxa o MAPE global (2,8%).

Esse padrão é compatível com calibração DEM/SC mais fraca em parte das HFUs. Não indica um mecanismo elástico novo aprendido pelo ML.


Plugs explicam o gap da física, não o residual do híbrido

Perfil OOF dos slides anteriores; faixa lateral = HFU lab intercalada em profundidade.

HFU	n	Plugs	MAPE gas.	MAPE híbr.
1	42	4	6,8	2,2
2	29	4	2,2	2,3
3	10	2	11,5	5,4
4	6	0	28,1	4,8

Separar dois efeitos

- **Gap Gassmann:** na HFU 4, sem plug (fallback na calibração), o viés físico chega a +1,31 km/s.
- **Erro que sobra no híbrido:** os $\approx 5\%$ de MAPE em HFU 3/4 não vêm da falta de plug; são o erro OOF do corretor, com n pequeno.



Perfil OOF: sônico, Gassmann e híbrido RF; faixa = HFU lab intercalada.


Seis regressores, mesmo alvo e mesmo protocolo

Cinco regressores da Etapa 1 mais Ridge. Alvo ΔV_p , oito entradas em X e OOF por blocos de profundidade são os mesmos; muda apenas o modelo.

Regressor	R^2 res.	MAPE	RMSE	Viés
Regressão linear	0,88	2,1	0,14	+0,00
Random Forest	0,79	2,8	0,18	+0,01
Gradient Boosting	0,69	3,0	0,22	+0,01
XGBoost	0,52	3,6	0,27	+0,02
Ridge ($\alpha = 1$)	0,14	6,1	0,36	+0,04
MLP	-0,04	6,5	0,40	+0,01
Gassmann	—	7,3	0,48	+0,27

Em resumo

MAPE, RMSE e viés medem o erro do híbrido OOF frente ao sônico; R^2 mede o ajuste do residual. Todos ficam abaixo do Gassmann puro (7,3%). Melhor MAPE: linear (2,1%); RF oficial: 2,8%.



MAPE de V_p híbrida por regressor; tracejado = Gassmann (7,3%); RF em destaque.

Hiperparâmetros: o que foi fixado e por quê

Configuração alinhada à Etapa 1; semente 42 em todos. Não houve varredura fina de profundidade máxima nem de taxa de aprendizado: com $n = 87$, o ponto é comparar famílias de modelos, não otimizar hiperparâmetros.

Modelo	Hiperparâmetros	Motivo
RF (oficial)	200 árvores; sem scaler	Mesma escolha da Etapa 1; complexidade limitada para reduzir sobreajuste
Grad. Boost.	200 árvores; sem scaler	Mesma família ensemble; comparação direta com RF
XGBoost	200 árvores; <code>reg:squarederror</code> ; $n_{\text{jobs}} = 1$	Mesmo número de árvores; uma thread para reprodutibilidade
Linear	OLS + StandardScaler	Referência interpretável; escala evita coeficientes dominados pela unidade
Ridge	$\alpha = 1$; sem scaler	Contraste com penalidade L_2 ; $\alpha = 1$ é o valor default
MLP	(128, 64); 500 épocas; early stop 15% val.; + scaler	Rede com capacidade alta; com $n = 87$, tende a instabilidade

Observação


O RF oficial permanece estável no OOF (MAPE 2,8%). A linear (2,1%) tem coeficientes legíveis. O Ridge perde porque $\alpha = 1$ atua sem padronizar X — não porque regularização L_2 seja inadequada em geral.

Linear e Ridge: efeito da escala das variáveis

- A **regressão linear** (OLS + scaler) tem o menor MAPE (2,1%) e o maior R^2 residual (0,88). Ou seja, o desvio pós-Gassmann acompanha de forma **aproximadamente linear** $V_{p,Gassmann}$ e os perfis de entrada.
- O **Ridge** ($\alpha = 1$) minimiza $\|y - Xw\|_2^2 + \alpha\|w\|_2^2$ sem padronizar X . Variáveis de escala grande (resistividades, por exemplo) incham $\|w\|$; a penalidade L_2 reduz os demais coeficientes e o modelo subajusta.
- O **MLP** fica por último (R^2 levemente negativo). Com $n = 87$ e capacidade alta, a instabilidade é esperada.

Hipótese de bom desempenho


Se a linear compete com o RF, a parte previsível do residual — $h(X)$ em $\Delta V_p = \mu_\Delta + h(X) + \varepsilon$ — é, neste poço, quase linear nas entradas. Há o que aprender, mas sem necessidade de um modelo fortemente não linear.



Perfis por regressor. MLP e Ridge oscilam; linear e RF acompanham o sônico.

RF versus linear em profundidade

Mesmo OOF; faixa lateral = HFU lab intercalada.



Sônico, híbrido RF (MAPE 2,8%) e híbrido linear (MAPE 2,1%).

Dois caminhos possíveis

- **RF (oficial):** mesma linha da Etapa 1; admite não linearidades locais; MAPE 2,8%.
- **Linear:** coeficientes legíveis; MAPE 2,1%.
- Os dois acompanham o sônico na coluna. Ridge e MLP ficam de fora.

Sobre $h(X)$

Nos slides anteriores escrevemos $\Delta V_p = \mu_\Delta + h(X) + \varepsilon$, com $h(X)$ previsível e ε residual. Como a linear compete com o RF, $h(X)$ parece **aproximadamente linear** neste intervalo: há estrutura, mas não é preciso árvore para aproveitá-la.

Conclusões

1. **HFU:** o ganho do híbrido está onde a física falhava (HFU 3/4). Na HFU 2 ($\approx 2\%$) o corretor quase não muda o erro. Rótulos intercalados, não zonas contíguas.
2. **Plugs:** explicam o gap do Gassmann (em especial HFU 4). Não explicam os $\approx 5\%$ de MAPE que restam no híbrido.
3. **Algoritmo:** RF (200 árvores, semente 42) e regressão linear (+ scaler) são os dois caminhos viáveis. Hiperparâmetros da Etapa 1; sem otimização agressiva em $n = 87$.
4. **Alcance:** resultado para este poço, sob OOF. Não demonstra transferência a outro poço e não substitui a cadeia DEM-Gassmann.